

Informe Técnico

Reposición Inteligente de Inventario (RII)

1. Formulación del problema

Ámbito de aplicación del proyecto:

Gestión de inventario y logística de reposición en el sector *retail* específicamente la planificación periódica de abastecimiento de un comercio multi-categoría (+8.000 SKU activos y 8 grupos de productos) con restricciones reales de capacidad de transporte.

Ayudar a la toma de decisiones sobre qué productos reponer, qué cantidad y con qué prioridad, dado un horizonte de abastecimiento trimestral y un camión con capacidad máxima de 8 toneladas por envío.

El problema se descompone en 3 ejes:

- Eje 1 — Segmentación estratégica
- Eje 2 — Predicción de demanda
- Eje 3 — Propuesta de reposición

Propuesta de valor del proyecto:

Reemplazar un criterio de reposición basado en intuición o reglas fijas por uno basado en datos:

- Segmentar productos por su importancia estratégica real
- Predecir demanda con un modelo validado
- Priorizar el uso del camión por rentabilidad del inventario ($GMROI = \text{Ganancia Bruta} / \text{Promedio del Inventario al Costo}$)


Métricas de éxito técnico: MAE/RMSE/ R^2 del modelo de demanda superando al *baseline* ingenuo y a la regresión lineal.

Métricas de éxito de negocio: % de capacidad del camión utilizada, % de valor GMROI capturado por el envío y que el segmento de mayor rentabilidad (A) sea efectivamente priorizado.



2. Análisis exploratorio de datos

Fuente de datos (dataset):

Historial real de movimientos de venta por producto (enero-julio 2026, 205 fechas, 8.309 productos). No se encontraron valores nulos ni filas duplicadas.



Se detectan devoluciones (venta negativa) y márgenes negativos (precios especiales). No es un error de carga, son casos reales y normales del negocio.



3. Diseño del pipeline

El diccionario de datos indica que los campos acumulados del *dataset* venta acumulada y stock promedio acumulado son desde el 01/01/2026 al 31/07/2026 lo cual hay riesgo de sesgo. Para evitarlo se recalculan sobre ventanas de calendario fijas iguales para todos los productos en lugar de usar los campos acumulados.

- Entrenamiento: features con datos de enero a mayo → predicen la demanda de junio.
- Prueba: features con datos de enero a junio → predicen la demanda real de julio (nunca vista por el modelo).
- Imputación: mediana para rotación/GMROI cuando el stock promedio de la ventana es 0.
- Escalado: estandarización de variables numéricas, codificación one-hot para Grupo, Marca se excluye por alta cardinalidad.
- Todo el preprocesamiento se ajusta únicamente con datos de entrenamiento (ColumnTransformer dentro de un Pipeline de scikit-learn), evitando la contaminación del *test*.


4. Resultados comparativos de modelos

4.1 Eje 2 — Predicción de demanda

Se comparó un *baseline* ingenuo (promedio histórico) y una regresión lineal contra dos familias de modelos (Random Forest y KNN) evaluados sobre julio:

Modelo	MAE	RMSE	R ²	Mejores hiperparámetros
<i>Baseline</i> ingenuo	3,67	18,19	—	—
Regresión Lineal	3,15	17,25	0,23	—
Random Forest	2,95	16,59	0,29	max_depth=5, n_estimators=300
KNN	2,72	17,68	0,19	n_neighbors=20, weights=distance


Los tres modelos superan al *baseline* ingenuo. Se eligió **Random Forest** como modelo final. KNN tiene MAE levemente menor sin embargo Random Forest tiene mejor RMSE y R² y es interpretable mediante importancia de variables.




La variable más influyente es la cantidad de observaciones históricas del producto (42% de la importancia)

La frecuencia de movimiento es mejor predictora de demanda futura que el margen o el costo y explica por qué los productos de venta esporádica son más difíciles de pronosticar

4.2 Eje 1 — Segmentación



El Silhouette más alto se da en $k=2$ y $k=3$ queda cerca (0,49 vs. 0,47), sin embargo, se eligió $k=3$ por comparabilidad directa con el esquema de negocio clásico A/B/C (análisis ABC) con una separación aún razonable. Además, tiene la gran ventaja de ser más entendible para los analistas comerciales.




El segmento A → mejor margen y rotación y el GMROI promedio es 4,24.

El segmento C → menor margen y rotación y el GMROI más bajo (0,39).

5. Análisis de costos del negocio

- 2.647 productos requieren reposición con un peso total de 5 toneladas.
- Uso de la capacidad del camión: 62,6%. No llega a saturarse con la demanda proyectada actual.
- Se captura el 100% del valor (GMROI-ponderado) de la demanda a reponer.



6. Conclusiones y limitaciones

- La segmentación confirma agrupamientos comparables al esquema A/B/C (análisis ABC clásico de gestión de inventario), usando margen y rotación calculados sobre una ventana fija para evitar el sesgo del *dataset* original.
- Random Forest mejora al *baseline* ingenuo y a la regresión lineal en la predicción de demanda con buen equilibrio entre error e interpretabilidad.
- La propuesta de reposición, priorizada por GMROI, usa la mayoría de la capacidad del camión sin llegar a saturarla.
- El modelo predice a nivel mensual y se proyecta a 3 meses asumiendo el supuesto de una demanda estable.